UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO
DEPARTAMENTO DE ESTATÍSTICA E INFORMÁTICA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

ALEXANDRE DE SIQUEIRA MELO JUNIOR

EFEITO DE TÉCNICAS DE NORMALIZAÇÃO SOBRE O TREINAMENTO DE REDES NEURAIS CONVOLUCIONAIS:

planejamento do experimento

RECIFE
2026

ALEXANDRE DE SIQUEIRA MELO JUNIOR

EFEITO DE TÉCNICAS DE NORMALIZAÇÃO SOBRE O TREINAMENTO DE REDES NEURAIS CONVOLUCIONAIS:

planejamento do experimento

Planejamento do experimento apresentado à disciplina Projetos para Sociedade II do Bacharelado em Sistemas de Informação da Universidade Federal Rural de Pernambuco, como etapa de elaboração do Trabalho de Conclusão de Curso.

Orientador: Prof. [nome do orientador]

RECIFE

2026

SUMÁRIO

1 INTRODUÇÃO 3
2 DEFINIÇÃO DO EXPERIMENTO 4
3 HIPÓTESES 5
4 VARIÁVEIS 7
5 DESENHO EXPERIMENTAL 8
5.1 CENÁRIOS E REPETIÇÕES 8
5.2 ORDEM DE EXECUÇÃO 8
6 OBJETOS E INSTRUMENTAÇÃO 9
6.1 CONJUNTO DE DADOS 9
6.2 ARQUITETURA DO MODELO 9
6.3 TÉCNICAS DE NORMALIZAÇÃO 10
6.4 HIPERPARÂMETROS 10
6.5 AMBIENTE DE EXECUÇÃO 11
6.6 INSTRUMENTOS DE MEDIÇÃO 11
6.7 VERIFICAÇÃO DA IMPLEMENTAÇÃO 12
7 PROCEDIMENTO DE EXECUÇÃO 13
7.1 EXPERIMENTO PILOTO 13
7.2 EXECUÇÃO DE CADA RODADA 13
7.3 INTERRUPÇÕES E RETOMADA 14
8 COLETA DE DADOS 15
9 PLANO DE ANÁLISE 16
10 AMEAÇAS À VALIDADE 18
11 CRONOGRAMA DO EXPERIMENTO 19
REFERÊNCIAS 20
APÊNDICE A – ORDEM DE EXECUÇÃO DAS RODADAS 21

1 INTRODUÇÃO

Este documento apresenta o planejamento do experimento do Trabalho de Conclusão de Curso, que compara técnicas de normalização no treinamento de uma rede neural convolucional. Ele detalha o que a metodologia da pesquisa apresenta de forma geral: a definição do objetivo, as hipóteses na forma estatística, as variáveis, o desenho experimental, os objetos e instrumentos, o procedimento de execução, a coleta dos dados, o plano de análise, as ameaças à validade e o cronograma.

O planejamento segue o processo de experimentação proposto por Wohlin *et al.* (2012), que organiza um experimento controlado em definição, planejamento, operação, análise e apresentação. O objetivo é que o experimento possa ser executado exatamente como descrito, por qualquer pessoa, e que nenhuma decisão de análise seja tomada depois de conhecidos os resultados.

2 DEFINIÇÃO DO EXPERIMENTO

O objetivo do experimento é definido segundo o modelo Objetivo/Pergunta/Métrica (GQM), adotado por Wohlin *et al.* (2012) para a definição de experimentos:

> **Analisar** técnicas de normalização em redes neurais convolucionais (Batch Normalization, Layer Normalization, Group Normalization e ausência de normalização), **com o propósito de** compará-las, **com respeito ao** desempenho preditivo, à velocidade de convergência, ao custo computacional e à estabilidade do treinamento, **do ponto de vista do** pesquisador e de quem desenvolve modelos de aprendizado profundo, **no contexto de** uma rede convolucional compacta treinada no conjunto Fashion-MNIST com lotes de 16 e 128 exemplos.

O Quadro 1 desdobra o objetivo em perguntas e métricas.

Quadro 1 – Objetivo, perguntas e métricas (GQM)

Pergunta	Métricas
P1. A técnica de normalização altera o desempenho preditivo, e esse efeito depende do tamanho do lote?	Acurácia e F1 macro no conjunto de teste
P2. As técnicas de normalização fazem a rede convergir em menos épocas que a condição sem normalização?	Épocas até 90% de acurácia de validação
P3. Qual é o custo computacional de cada técnica?	Tempo por época, tempo até a meta, tempo total e memória máxima na GPU
P4. A ausência de normalização torna o treinamento menos estável?	Execuções com perda divergente; desvio-padrão da acurácia de teste entre sementes

Fonte: elaborado pelo autor (2026).

3 HIPÓTESES

As hipóteses de pesquisa da metodologia (H1 a H5) são traduzidas em hipóteses estatísticas, cada uma com uma hipótese nula (H_0), a ser rejeitada, e uma alternativa (H_a). Nas expressões, μ representa a média da métrica sobre as sementes, e os índices BN, LN, GN e SN indicam Batch Normalization, Layer Normalization, Group Normalization e ausência de normalização.

Desempenho preditivo (P1; hipóteses de pesquisa H1 e H2)

a) **H_{01}** — a técnica de normalização não altera a acurácia média de teste: $\mu_{BN} = \mu_{LN} = \mu_{GN} = \mu_{SN}$. **$H_{a1}$** — ao menos uma técnica tem média diferente;
b) **H_{02}** — o tamanho do lote não altera a acurácia média de teste: $\mu_{16} = \mu_{128}$. **H_{a2}** — as médias diferem;
c) **H_{03}** — não há interação entre técnica e tamanho do lote. **H_{a3}** — o efeito da técnica depende do tamanho do lote. A rejeição de H_{03}, seguida das comparações dentro de cada lote, é o que permite avaliar H1 (com lote 16, μ_{GN} e $\mu_{LN} \geq \mu_{BN}$) e H2 (com lote 128, $\mu_{BN} \geq \mu_{GN}$ e μ_{LN}).
   As mesmas hipóteses são testadas para o F1 macro de teste.

Convergência (P2; hipótese de pesquisa H3)

a) **H_{04}** — as técnicas de normalização exigem o mesmo número médio de épocas até a meta que a condição sem normalização: $\mu_{BN} = \mu_{SN}$, $\mu_{LN} = \mu_{SN}$ e $\mu_{GN} = \mu_{SN}$. **H_{a4}** — cada técnica de normalização exige menos épocas que a condição sem normalização (teste unilateral).

Custo (P3; hipótese de pesquisa H4)

a) **H_{05}** — as técnicas de normalização têm o mesmo tempo médio por época que a condição sem normalização. **H_{a5}** — cada técnica de normalização tem tempo por época maior;

b) $\mathbf{H_{06}}$ — as técnicas de normalização têm o mesmo tempo médio até a meta que a condição sem normalização. $\mathbf{H_{a6}}$ — cada técnica de normalização tem tempo até a meta menor.

Estabilidade (P4; hipótese de pesquisa H5)

a) $\mathbf{H_{07}}$ — a variância da acurácia de teste entre sementes é igual em todas as técnicas. $\mathbf{H_{a7}}$ — ao menos uma técnica tem variância diferente;
b) $\mathbf{H_{08}}$ — a proporção de execuções divergentes é igual com e sem normalização. $\mathbf{H_{a8}}$ — a proporção é maior sem normalização.

4 VARIÁVEIS

O Quadro 2 apresenta as variáveis do experimento. As variáveis independentes são manipuladas pelo pesquisador; as dependentes são medidas em cada execução; as controladas são mantidas idênticas em todas as execuções, para que as diferenças observadas possam ser atribuídas apenas aos fatores.

Quadro 2 – Variáveis do experimento

Tipo	Variável	Níveis ou escala
Independente (fator)	Técnica de normalização	Batch Normalization; Layer Normalization; Group Normalization; sem normalização
Independente (fator)	Tamanho do lote	16; 128
Dependente	Acurácia de teste	Proporção, de 0 a 1
Dependente	F1 macro de teste	Proporção, de 0 a 1
Dependente	Épocas até a meta	Número inteiro de 1 a 30; não convergente quando a meta não é atingida
Dependente	Tempo por época, tempo até a meta e tempo total	Segundos
Dependente	Memória máxima	Megabytes
Dependente	Divergência	Sim ou não, por execução
Controlada	Arquitetura, ativação, posição da normalização, inicialização, otimizador, taxa de aprendizado, número máximo de épocas, parada antecipada, pré-processamento, divisão dos dados, hardware e versões das bibliotecas	Valores fixos descritos na seção 6

Fonte: elaborado pelo autor (2026).

5 DESENHO EXPERIMENTAL

5.1 CENÁRIOS E REPETIÇÕES

O experimento adota um **desenho fatorial completo 4 × 2**, em que todas as combinações dos níveis dos dois fatores são testadas (Montgomery, 2017). As oito combinações formam os cenários do Quadro 3. Cada cenário é executado com cinco sementes aleatórias (0, 1, 2, 3 e 4), totalizando **40 execuções**, número de repetições que segue o procedimento de Kazimi e Sandfeld (2025).

Quadro 3 – Cenários do experimento

Cenário	Técnica de normalização	Lote	Execuções
C1	Batch Normalization	16	C1-S0 a C1-S4
C2	Layer Normalization	16	C2-S0 a C2-S4
C3	Group Normalization	16	C3-S0 a C3-S4
C4	Sem normalização	16	C4-S0 a C4-S4
C5	Batch Normalization	128	C5-S0 a C5-S4
C6	Layer Normalization	128	C6-S0 a C6-S4
C7	Group Normalization	128	C7-S0 a C7-S4
C8	Sem normalização	128	C8-S0 a C8-S4

Fonte: elaborado pelo autor (2026).

A semente é tratada como um **bloco**: a mesma semente produz, em todos os cenários, a mesma divisão entre treino e validação, a mesma ordem de apresentação dos exemplos e a mesma inicialização das camadas comuns. Assim, as comparações entre técnicas são pareadas, e a variação entre sementes pode ser separada da variação entre técnicas.

5.2 ORDEM DE EXECUÇÃO

As 40 execuções são feitas em **ordem aleatória**, e não cenário por cenário. Isso evita que variações do ambiente ao longo do tempo — como mudanças de desempenho da GPU compartilhada do Google Colab — se confundam com o efeito de um cenário (Wohlin *et al.*, 2012). A ordem foi sorteada uma única vez, por um programa com semente fixa (2026), e está registrada no Apêndice A; ela não pode ser alterada após o início do experimento.

6 OBJETOS E INSTRUMENTAÇÃO

6.1 CONJUNTO DE DADOS

O objeto do experimento é o conjunto **Fashion-MNIST** (Xiao; Rasul; Vollgraf, 2017): 70.000 imagens em tons de cinza de 28 × 28 pixels, de dez classes de artigos de vestuário, com 60.000 imagens de treino e 10.000 de teste na divisão oficial. Em cada semente, 10% das imagens de treino (6.000) são separadas para validação de forma estratificada, preservando a proporção das classes; as 54.000 restantes são usadas no treinamento. O conjunto de teste é o oficial e só é usado uma vez, ao final de cada execução.

Os valores dos pixels são convertidos para o intervalo [0, 1] e padronizados com a média e o desvio-padrão calculados sobre as imagens de treino. Não há aumento de dados. Esse pré-processamento é idêntico em todos os cenários e não faz parte das técnicas comparadas, que atuam nas camadas internas da rede.

6.2 ARQUITETURA DO MODELO

Todas as execuções usam a rede convolucional compacta do Quadro 4, com aproximadamente 104 mil parâmetros treináveis. Em cada bloco, a camada de normalização fica entre a convolução e a ativação ReLU, como em Ioffe e Szegedy (2015); na condição sem normalização, ela é substituída pela função identidade.

Quadro 4 – Arquitetura da rede neural convolucional

Bloco	Camadas	Saída
Entrada	Imagem em tons de cinza	1 × 28 × 28
Bloco 1	Convolução 3 × 3 com 32 filtros → normalização → ReLU → *max pooling* 2 × 2	32 × 14 × 14
Bloco 2	Convolução 3 × 3 com 64 filtros → normalização → ReLU → *max pooling* 2 × 2	64 × 7 × 7
Bloco 3	Convolução 3 × 3 com 128 filtros → normalização → ReLU → *max pooling* 2 × 2	128 × 3 × 3
Classificador	Achatamento → *dropout* (0,3) → camada densa com 10 neurônios	10 classes

Fonte: elaborado pelo autor (2026).

6.3 TÉCNICAS DE NORMALIZAÇÃO

As técnicas diferem apenas no conjunto de valores sobre o qual são calculadas a média e a variância usadas na normalização, como resume o Quadro 5. As três incluem os parâmetros aprendidos de escala e deslocamento.

Quadro 5 – Configuração das técnicas de normalização

Técnica	Estatísticas calculadas sobre	Implementação no PyTorch
Batch Normalization (Ioffe; Szegedy, 2015)	Cada canal, sobre todos os exemplos do lote e todas as posições; na inferência, médias móveis do treino	BatchNorm2d (momento 0,1; $\varepsilon = 10^{-5}$)
Layer Normalization (Ba; Kiros; Hinton, 2016)	Todos os canais e posições de um único exemplo	GroupNorm com 1 grupo (equivalente à normalização por camada em mapas convolucionais)
Group Normalization (Wu; He, 2018)	Grupos de canais de um único exemplo	GroupNorm com 8 grupos
Sem normalização	—	Identity

Fonte: elaborado pelo autor (2026).

O número de oito grupos divide o número de canais dos três blocos (32, 64 e 128), resultando em grupos de 4, 8 e 16 canais.

6.4 HIPERPARÂMETROS

O Quadro 6 fixa os hiperparâmetros, iguais em todos os cenários. Eles não serão ajustados por cenário: ajustar a taxa de aprendizado para cada técnica mudaria duas condições ao mesmo tempo e impediria atribuir as diferenças à normalização.

Quadro 6 – Hiperparâmetros do treinamento

Hiperparâmetro	Valor
Otimizador	Adam ($\beta_1 = 0,9$; $\beta_2 = 0,999$)
Taxa de aprendizado	0,001, constante, igual para os dois tamanhos de lote
Função de perda	Entropia cruzada
Número máximo de épocas	30
Parada antecipada	Após 5 épocas sem redução da perda de validação, restaurando os pesos da melhor época
Dropout	0,3, antes da camada densa
Inicialização dos pesos	Padrão do PyTorch para cada camada
Regularização dos pesos	Nenhuma
Sementes	0, 1, 2, 3 e 4

Fonte: elaborado pelo autor (2026).

6.5 AMBIENTE DE EXECUÇÃO

O experimento será implementado em Python, com PyTorch (Paszke *et al.*, 2019) para as redes, torchvision para o carregamento do Fashion-MNIST, scikit-learn para a divisão estratificada e o F1, pandas para o registro dos resultados e SciPy e statsmodels para a análise estatística. A execução ocorrerá no Google Colab com GPU. O modelo da GPU, as versões das bibliotecas e a data de cada execução são registrados; as comparações de tempo e de memória só são feitas entre execuções no mesmo modelo de GPU.

6.6 INSTRUMENTOS DE MEDIÇÃO

Cada métrica é medida por um procedimento fixo, descrito a seguir:

- **tempo** — medido com o relógio de alta resolução do Python, com sincronização da GPU antes de cada leitura, já que as operações em GPU são assíncronas. O tempo por época considera apenas o treino, sem a avaliação na validação; a média por execução descarta a primeira época, afetada pela inicialização da GPU. O tempo até a meta é a soma dos tempos de treino até a época que atinge a meta;

- **memória** — o contador de pico de memória da GPU é zerado no início de cada execução e lido ao final, registrando a maior quantidade de memória alocada durante o treinamento;
- **divergência** — a cada passo de treinamento, verifica-se se a perda é um número finito. Se não for, a execução é interrompida e registrada como divergente;
- **desempenho** — a acurácia e o F1 macro são calculados sobre as 10.000 imagens de teste, com os pesos da melhor época de validação.

6.7 VERIFICAÇÃO DA IMPLEMENTAÇÃO

Antes do piloto, o código passa por testes automatizados que verificam se ele faz o que este planejamento descreve:

- dada uma entrada aleatória, cada camada de normalização produz saída com média próxima de zero e variância próxima de um sobre o conjunto de valores definido no Quadro 5;
- dada a mesma semente, duas execuções curtas produzem as mesmas perdas e os mesmos pesos;
- dadas as quatro técnicas, as redes diferem apenas na camada de normalização, e o número de parâmetros difere apenas pelos parâmetros de escala e deslocamento;
- dada uma perda não finita simulada, a execução é interrompida e marcada como divergente;
- dada a divisão de uma semente, treino e validação não compartilham imagens e preservam a proporção das classes.

7 PROCEDIMENTO DE EXECUÇÃO

7.1 EXPERIMENTO PILOTO

O piloto executa os oito cenários com uma semente extra (semente 99), que não faz parte das 40 execuções. Ele serve para verificar o código no ambiente real e estimar o tempo total. Os critérios e as decisões do piloto são definidos antecipadamente:

a) se alguma execução falhar por erro de programa, o erro é corrigido, os testes da seção 6.7 são executados novamente e o piloto é repetido;
b) se menos da metade dos cenários atingir a meta de 90% de acurácia de validação, a meta passa a ser 88%, para que a métrica de convergência diferencie as condições;
c) se a estimativa de tempo das 40 execuções ultrapassar 12 horas de GPU, o número máximo de épocas passa de 30 para 20.

Encerrado o piloto, o protocolo é **congelado**: nenhuma alteração de código, hiperparâmetro ou critério é permitida durante a execução das 40 rodadas, e os resultados do piloto não entram na análise.

7.2 EXECUÇÃO DE CADA RODADA

Cada uma das 40 execuções, na ordem do Apêndice A, segue os passos abaixo:

a) fixar a semente do Python, do NumPy e do PyTorch e ativar os algoritmos determinísticos do PyTorch;
b) gerar a divisão estratificada entre treino e validação correspondente à semente;
c) construir a rede com a técnica do cenário e criar o carregador de dados com o tamanho de lote do cenário;
d) zerar o contador de pico de memória da GPU;
e) para cada época: treinar, verificando a perda a cada passo; medir o tempo de treino; avaliar perda e acurácia de validação; registrar a linha da época; verificar se a meta foi atingida e se a parada antecipada deve ocorrer;

f) restaurar os pesos da época com menor perda de validação e avaliar no conjunto de teste;
g) registrar a linha da execução, com todas as métricas, e salvar os arquivos antes de iniciar a execução seguinte.

7.3 INTERRUPÇÕES E RETOMADA

As sessões do Google Colab podem ser encerradas antes do fim do experimento. Como as execuções são independentes e cada uma grava seus resultados ao terminar, uma interrupção afeta apenas a execução em andamento. Na retomada, o programa lê o arquivo de resultados, identifica as execuções concluídas e reinicia a primeira não concluída, do início, mantendo a ordem do Apêndice A. Os arquivos são gravados no Google Drive para não se perderem com o fim da sessão.

8 COLETA DE DADOS

Os dados são gravados em dois arquivos CSV. O primeiro tem uma linha por execução, com as métricas finais (Quadro 7); o segundo tem uma linha por época, com as curvas de treinamento (Quadro 8).

Quadro 7 – Estrutura do arquivo de execuções (execucoes.csv)

Coluna	Conteúdo
ordem, execucao, cenario	Posição na ordem sorteada e identificadores (por exemplo, 7, C3-S2, C3)
tecnica, lote, semente	Níveis dos fatores e semente da execução
epocas_executadas, melhor_epoca	Épocas efetivamente treinadas e época restaurada
epoca_meta	Primeira época com acurácia de validação ≥ meta; vazio se não atingida
tempo_medio_epoca_s, tempo_meta_s, tempo_total_s	Medidas de tempo, em segundos
memoria_max_mb	Pico de memória alocada na GPU
acc_teste, f1_macro_teste, perda_teste	Desempenho no conjunto de teste
divergiu	1 se houve perda não finita; 0 caso contrário
gpu, versao_python, versao_torch, data_hora	Ambiente e momento da execução

Fonte: elaborado pelo autor (2026).

Quadro 8 – Estrutura do arquivo de épocas (epocas.csv)

Coluna	Conteúdo
execucao, epoca	Identificador da execução e número da época
perda_treino, acc_treino	Média da perda e acurácia no treino da época
perda_val, acc_val	Perda e acurácia na validação ao final da época
tempo_epoca_s	Tempo de treino da época, em segundos

Fonte: elaborado pelo autor (2026).

9 PLANO DE ANÁLISE

A análise é definida antes da coleta dos dados e segue três passos. Primeiro, a **estatística descritiva**: média, desvio-padrão e intervalo de confiança de 95% de cada métrica por cenário, além dos gráficos descritos adiante. Segundo, a **verificação dos pressupostos** da análise de variância: normalidade dos resíduos, pelo teste de Shapiro-Wilk, e homogeneidade das variâncias, pelo teste de Levene. Terceiro, os **testes de hipóteses** do Quadro 9, com nível de significância de 5%.

Quadro 9 – Testes estatísticos por hipótese

Hipótese	Variável	Teste principal	Alternativa se os pressupostos falharem
H_{01}, H_{02}, H_{03}	Acurácia e F1 de teste	ANOVA com dois fatores e interação; comparações de Tukey dentro de cada lote	Kruskal-Wallis dentro de cada lote, com teste de Dunn e correção de Holm
H_{04}	Épocas até a meta	Comparação de cada técnica com o controle pelo teste de Dunnett, unilateral, dentro de cada lote	Teste de Mann-Whitney unilateral com correção de Holm
H_{05}, H_{06}	Tempo por época e tempo até a meta	Teste de Dunnett unilateral, dentro de cada lote	Teste de Mann-Whitney unilateral com correção de Holm
H_{07}	Acurácia de teste	Teste de Brown-Forsythe para igualdade de variâncias	—
H_{08}	Divergência	Teste exato de Fisher (sem normalização × com normalização)	—

Fonte: elaborado pelo autor (2026).

A ANOVA e o teste de Dunnett, que compara cada tratamento a um controle — aqui, a condição sem normalização —, são descritos por Montgomery (2017). As execuções que não atingem a meta recebem o valor 31 épocas, uma a mais que o máximo permitido. Se houver alguma execução nessa situação, H_{04} é testada pela alternativa baseada em postos, que não depende do valor exato atribuído; o número dessas execuções é relatado por cenário. As execuções divergentes entram na análise de estabilidade; na de desempenho, os resultados são apresentados com e sem elas.

Como cinco repetições por cenário oferecem poder estatístico limitado, cada teste vem acompanhado do tamanho do efeito (η^2 parcial na ANOVA) e de uma **regra de equivalência prática**: duas técnicas são equivalentes em desempenho

quando a diferença absoluta entre as acurácias médias de teste é de no máximo um ponto percentual. Entre técnicas equivalentes, a recomendação é a de menor tempo até a meta e menor variabilidade.

Os resultados serão apresentados nos seguintes gráficos:

- curvas de perda e de acurácia de validação por época, com a média e a faixa entre sementes, para cada cenário;
- diagramas de caixa da acurácia de teste por técnica, separados por tamanho de lote;
- gráfico de interação, com a acurácia média de cada técnica nos dois tamanhos de lote;
- gráficos de barras do tempo até a meta e da memória máxima por cenário.

10 AMEAÇAS À VALIDADE

As ameaças são organizadas nas quatro categorias de Wohlin *et al.* (2012):

- **validade de conclusão** — cinco repetições por cenário limitam o poder dos testes; a mitigação é relatar intervalos de confiança, tamanhos de efeito e a regra de equivalência prática, além dos valores-p;
- **validade interna** — o não determinismo de algumas operações em GPU e a variação de desempenho do ambiente compartilhado podem alterar resultados e tempos; a mitigação é usar algoritmos determinísticos, executar em ordem aleatória, registrar o modelo da GPU e comparar tempos apenas no mesmo hardware;
- **validade de construto** — a meta de 90% é uma escolha do pesquisador e pode favorecer algumas condições; por isso, as curvas completas de validação também são analisadas. A taxa de aprendizado fixa isola o fator lote, mas pode desfavorecer o lote grande, já que a taxa ideal varia com o lote (Mishkin; Sergievskiy; Matas, 2017);
- **validade externa** — os resultados se referem a uma rede compacta e a um único conjunto de dados de pequena escala, e não devem ser generalizados para redes profundas ou outras tarefas sem novos experimentos.

11 CRONOGRAMA DO EXPERIMENTO

O experimento ocupa os meses 2 a 4 do cronograma da pesquisa, distribuídos nas semanas do Quadro 10.

Quadro 10 – Cronograma do experimento

Atividade	Sem. 1	Sem. 2	Sem. 3	Sem. 4	Sem. 5	Sem. 6	Sem. 7
Implementação do código e dos testes automatizados	X	X					
Experimento piloto e congelamento do protocolo			X				
Execução das 40 rodadas				X	X		
Verificação dos dados coletados					X		
Análise estatística e gráficos						X	X

Fonte: elaborado pelo autor (2026).

REFERÊNCIAS

BA, J. L.; KIROS, J. R.; HINTON, G. E. Layer normalization. **arXiv preprint**, arXiv:1607.06450, 2016.

IOFFE, S.; SZEGEDY, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. *In*: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 32., 2015. **Proceedings** […]. [*S. l.*]: PMLR, 2015. v. 37, p. 448-456.

KAZIMI, B.; SANDFELD, S. Enhancing semantic segmentation in high-resolution TEM images: a comparative study of batch normalization and instance normalization. **Microscopy and Microanalysis**, v. 31, n. 1, ozae093, 2025. DOI: 10.1093/mam/ozae093.

MISHKIN, D.; SERGIEVSKIY, N.; MATAS, J. Systematic evaluation of convolution neural network advances on the Imagenet. **Computer Vision and Image Understanding**, v. 161, p. 11-19, 2017. DOI: 10.1016/j.cviu.2017.05.007.

MONTGOMERY, D. C. **Design and analysis of experiments**. 9. ed. Hoboken: Wiley, 2017.

PASZKE, A. *et al.* PyTorch: an imperative style, high-performance deep learning library. *In*: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 32., 2019. **Proceedings** […]. [*S. l.*]: Curran Associates, 2019. p. 8024-8035.

WOHLIN, C. *et al.* **Experimentation in software engineering**. Berlin: Springer, 2012.

WU, Y.; HE, K. Group normalization. *In*: EUROPEAN CONFERENCE ON COMPUTER VISION, 2018. **Proceedings** […]. Cham: Springer, 2018. p. 3-19. DOI: 10.1007/978-3-030-01261-8_1.

XIAO, H.; RASUL, K.; VOLLGRAF, R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms. **arXiv preprint**, arXiv:1708.07747, 2017.

APÊNDICE A – ORDEM DE EXECUÇÃO DAS RODADAS

A ordem abaixo foi sorteada pelo algoritmo de Fisher-Yates, com gerador pseudoaleatório de semente fixa (2026), e deve ser seguida na execução do experimento.

Quadro 11 – Ordem de execução das 40 rodadas

Ordem	Execução	Técnica de normalização	Lote	Semente
1	C6-S3	Layer Normalization	128	3
2	C6-S2	Layer Normalization	128	2
3	C5-S4	Batch Normalization	128	4
4	C6-S4	Layer Normalization	128	4
5	C8-S4	Sem normalização	128	4
6	C5-S0	Batch Normalization	128	0
7	C7-S3	Group Normalization	128	3
8	C1-S2	Batch Normalization	16	2
9	C7-S4	Group Normalization	128	4
10	C2-S1	Layer Normalization	16	1
11	C8-S1	Sem normalização	128	1
12	C4-S4	Sem normalização	16	4
13	C3-S3	Group Normalization	16	3
14	C7-S2	Group Normalization	128	2
15	C3-S1	Group Normalization	16	1
16	C4-S0	Sem normalização	16	0
17	C4-S1	Sem normalização	16	1
18	C3-S4	Group Normalization	16	4
19	C8-S0	Sem normalização	128	0
20	C8-S2	Sem normalização	128	2
21	C1-S0	Batch Normalization	16	0
22	C8-S3	Sem normalização	128	3
23	C5-S1	Batch Normalization	128	1
24	C7-S1	Group Normalization	128	1
25	C2-S3	Layer Normalization	16	3
26	C1-S4	Batch Normalization	16	4
27	C1-S3	Batch Normalization	16	3
28	C3-S0	Group Normalization	16	0

Ordem	Execução	Técnica de normalização	Lote	Semente
29	C4-S2	Sem normalização	16	2
30	C7-S0	Group Normalization	128	0
31	C1-S1	Batch Normalization	16	1
32	C2-S4	Layer Normalization	16	4
33	C6-S1	Layer Normalization	128	1
34	C5-S3	Batch Normalization	128	3
35	C2-S2	Layer Normalization	16	2
36	C2-S0	Layer Normalization	16	0
37	C5-S2	Batch Normalization	128	2
38	C6-S0	Layer Normalization	128	0
39	C3-S2	Group Normalization	16	2
40	C4-S3	Sem normalização	16	3

Fonte: elaborado pelo autor (2026).