UNIVERSIDADE FEDERAL RURAL DE PERNAMBUCO
DEPARTAMENTO DE ESTATÍSTICA E INFORMÁTICA
BACHARELADO EM SISTEMAS DE INFORMAÇÃO

ALEXANDRE DE SIQUEIRA MELO JUNIOR

EFEITO DE TÉCNICAS DE NORMALIZAÇÃO SOBRE O TREINAMENTO DE REDES NEURAIS CONVOLUCIONAIS:

planejamento da metodologia da pesquisa

RECIFE
2026

ALEXANDRE DE SIQUEIRA MELO JUNIOR

EFEITO DE TÉCNICAS DE NORMALIZAÇÃO SOBRE O TREINAMENTO DE REDES NEURAIS CONVOLUCIONAIS:

planejamento da metodologia da pesquisa

Planejamento da metodologia da pesquisa apresentado à disciplina Projetos para Sociedade II do Bacharelado em Sistemas de Informação da Universidade Federal Rural de Pernambuco, como etapa de elaboração do Trabalho de Conclusão de Curso.

Orientador: Prof. [nome do orientador]

RECIFE

2026

SUMÁRIO

3 METODOLOGIA 3
3.1 CARACTERIZAÇÃO DA PESQUISA 3
3.2 ETAPAS DA PESQUISA 3
3.3 REVISÃO DA LITERATURA 4
3.4 QUESTÃO DE PESQUISA E HIPÓTESES 5
3.5 VISÃO GERAL DO EXPERIMENTO 6
3.6 ANÁLISE DOS DADOS 7
3.7 CRONOGRAMA 7
REFERÊNCIAS 9

3 METODOLOGIA

Este capítulo descreve como a pesquisa será conduzida: a sua caracterização, as etapas, o protocolo da revisão da literatura, a questão de pesquisa e as hipóteses, a visão geral do experimento, a forma de análise dos dados e o cronograma. As decisões metodológicas são justificadas pela análise do conjunto base de artigos, que identificou a lacuna que o trabalho pretende preencher. O detalhamento operacional do experimento — objetos, instrumentação, procedimento de execução, coleta de dados e plano de análise — é apresentado no documento de Planejamento do Experimento.

3.1 CARACTERIZAÇÃO DA PESQUISA

Quanto à natureza, a pesquisa é **aplicada**, pois busca gerar conhecimento de uso prático sobre a escolha de técnicas de normalização no treinamento de redes neurais. Quanto à abordagem, é **quantitativa**: os efeitos das técnicas serão medidos por métricas numéricas e comparados por procedimentos estatísticos. Quanto aos objetivos, é **explicativa**, porque procura identificar como fatores controlados — a técnica de normalização e o tamanho do lote — determinam o comportamento do treinamento (Gil, 2017).

Quanto aos procedimentos técnicos, a pesquisa combina a **pesquisa bibliográfica**, usada para fundamentar o problema e definir as técnicas comparadas, com a **pesquisa experimental**, em que o pesquisador manipula variáveis independentes, controla as demais condições e observa o efeito sobre as variáveis dependentes (Gil, 2017). Em Computação, esse tipo de estudo é adequado quando se deseja comparar alternativas técnicas em condições controladas e reprodutíveis (Wazlawick, 2014).

3.2 ETAPAS DA PESQUISA

A pesquisa está organizada em seis etapas sequenciais, apresentadas no Quadro 1.

Quadro 1 – Etapas da pesquisa

Etapa	Descrição	Produto
1. Revisão da literatura	Busca nas bases definidas, triagem por critérios objetivos e análise do conjunto base de artigos.	Conjunto base, *insights* e lacuna de pesquisa
2. Planejamento	Definição da metodologia da pesquisa e planejamento detalhado do experimento.	Este documento e o Planejamento do Experimento
3. Implementação	Desenvolvimento e teste do código de preparação dos dados, treinamento, registro de métricas e análise.	Código versionado e testado
4. Experimento piloto	Execução de uma semente por cenário para validar o código e estimar o tempo total.	Protocolo congelado e estimativa de custo
5. Execução do experimento	Execução das 40 rodadas de treinamento no mesmo ambiente.	Base de resultados em CSV
6. Análise e redação	Estatística descritiva e inferencial, gráficos, discussão e conclusões.	Capítulos 4, 5 e 6 do TCC

Fonte: elaborado pelo autor (2026).

3.3 REVISÃO DA LITERATURA

A revisão segue um protocolo inspirado nos procedimentos de revisão sistemática, com o objetivo de identificar estudos revisados por pares que avaliem empiricamente o efeito de técnicas de normalização sobre o treinamento de redes neurais. A busca é realizada nas bases IEEE Xplore e ACM Digital Library, específicas da Computação, e na Scopus, indexadora multidisciplinar, todas acessadas pelo Portal de Periódicos da CAPES. Web of Science e SciELO são usadas como bases complementares. Uma busca piloto reprodutível foi executada no OpenAlex, base aberta, e está registrada em um notebook do Google Colab.

A *string* combina dois blocos obrigatórios, aplicados ao título, ao resumo e às palavras-chave: o bloco de intervenção, com os nomes das técnicas de normalização, e o bloco de modelo, com termos de redes neurais convolucionais e classificação de imagens. Os resultados são filtrados para artigos de periódico publicados entre 2015, ano de publicação da *Batch Normalization* (Ioffe; Szegedy, 2015), e 2026. A triagem usa apenas metadados e os critérios do Quadro 2.

Quadro 2 – Critérios de seleção dos estudos

Código	Critério	Decisão
I1	Publicação revisada por pares em periódico.	Incluir somente se atendido
I2	Periódico com classificação Qualis A1, A2, A3, A4 ou B1.	Incluir somente se atendido
I3	Título, resumo ou palavras-chave indicam experimento, comparação, *benchmark* ou avaliação.	Incluir somente se atendido
E1	*Preprint*, editorial, capítulo, tese, revisão ou tutorial.	Excluir
E2	Periódico sem ISSN ou sem Qualis elegível.	Excluir
E3	Ausência de indício explícito de avaliação empírica.	Excluir

Fonte: elaborado pelo autor (2026).

Na busca piloto, a *string* recuperou 3.400 artigos de periódico; os 300 mais relevantes foram triados, e 178 atenderam aos critérios I1 e I3, restando a verificação do Qualis. Como a maioria desses estudos apenas emprega a *Batch Normalization* como componente de aplicações, o conjunto base foi restrito aos artigos em que a normalização é o objeto da avaliação e cujo texto completo está disponível. A análise desse conjunto mostrou que a vantagem de cada técnica depende do tamanho do lote, da arquitetura e da tarefa (Wu; He, 2018; Mishkin; Sergievskiy; Matas, 2017; Kazimi; Sandfeld, 2025), que a normalização reduz o número de épocas mas aumenta o custo de cada iteração (Wu *et al.*, 2019) e que os estudos de escala acessível comparam no máximo duas condições e raramente repetem os experimentos (Kathayat; Akurathi; Thalla, 2025).

3.4 QUESTÃO DE PESQUISA E HIPÓTESES

A pesquisa busca responder à seguinte questão principal:

> Em uma rede neural convolucional de classificação de imagens, como Batch Normalization, Layer Normalization e Group Normalization, comparadas à ausência de normalização, afetam o desempenho preditivo, a velocidade de convergência, a estabilidade e o custo do treinamento sob diferentes tamanhos de lote?

Com base na literatura analisada, são formuladas as seguintes hipóteses de pesquisa, cuja formulação estatística — hipóteses nula e alternativa e testes associados — consta no Planejamento do Experimento:

a) **H1** — com lote pequeno (16), Group Normalization e Layer Normalization alcançam acurácia de teste igual ou superior à da Batch Normalization, porque não dependem das estatísticas do lote (Wu; He, 2018);
b) **H2** — com lote grande (128), a Batch Normalization alcança acurácia de teste igual ou superior à das demais técnicas (Ioffe; Szegedy, 2015; Wu; He, 2018);
c) **H3** — todas as técnicas de normalização atingem a meta de acurácia de validação em menos épocas que a condição sem normalização (Ioffe; Szegedy, 2015);
d) **H4** — as técnicas de normalização aumentam o tempo por época em relação à condição sem normalização, mas reduzem o tempo até a meta (Wu *et al.*, 2019);
e) **H5** — a condição sem normalização apresenta maior variabilidade entre sementes e mais execuções instáveis (Brock *et al.*, 2021; Nguyen; Choi; Yang, 2023).

3.5 VISÃO GERAL DO EXPERIMENTO

O experimento adota um **desenho fatorial completo 4 × 2**. O primeiro fator é a técnica de normalização, com quatro níveis — Batch Normalization, Layer Normalization, Group Normalization e ausência de normalização —; o segundo é o tamanho do lote, com dois níveis, 16 e 128 exemplos. Cada um dos oito cenários é repetido com cinco sementes aleatórias, totalizando 40 execuções de treinamento, número de repetições que segue o procedimento de Kazimi e Sandfeld (2025).

Todos os cenários usam a mesma rede neural convolucional compacta, com três blocos convolucionais e ativação ReLU, treinada no conjunto Fashion-MNIST (Xiao; Rasul; Vollgraf, 2017). Somente os dois fatores variam entre os cenários; arquitetura, otimizador, taxa de aprendizado, critério de parada, divisão dos dados e ambiente são mantidos constantes, porque o efeito da normalização depende da função de ativação e da posição da camada (Mishkin; Sergievskiy; Matas, 2017). A escala reduzida do conjunto de dados é adequada, pois experimentos com imagens pequenas preservam as conclusões qualitativas sobre a estrutura das redes (Mishkin; Sergievskiy; Matas, 2017).

As variáveis dependentes cobrem as quatro dimensões do problema: **desempenho** (acurácia e F1 macro no teste), **convergência** (épocas até 90% de

acurácia de validação), **custo** (tempo por época, tempo até a meta, tempo total e memória máxima) e **estabilidade** (execuções divergentes e desvio-padrão entre sementes). O experimento será implementado em Python com PyTorch (Paszke *et al.*, 2019) e executado no Google Colab com GPU.

3.6 ANÁLISE DOS DADOS

Os resultados serão resumidos por média, desvio-padrão e intervalo de confiança de 95% em cada cenário, e as curvas de treinamento serão apresentadas graficamente. A comparação inferencial usará a análise de variância com dois fatores, que permite testar o efeito da técnica, do tamanho do lote e da interação entre ambos (Montgomery, 2017), com alternativas não paramétricas caso os pressupostos não sejam atendidos. Como cinco repetições por cenário oferecem poder estatístico limitado, a significância estatística será complementada por uma regra de equivalência prática: duas técnicas serão consideradas equivalentes em desempenho quando a diferença entre as acurácias médias de teste for de no máximo um ponto percentual; entre técnicas equivalentes, prevalece a de menor custo e maior estabilidade.

3.7 CRONOGRAMA

O Quadro 3 apresenta a distribuição das etapas ao longo dos seis meses previstos para a execução do TCC.

Quadro 3 – Cronograma da pesquisa

Atividade	Mês 1	Mês 2	Mês 3	Mês 4	Mês 5	Mês 6
Complementação da busca nas bases CAPES e verificação Qualis	X					
Redação da fundamentação teórica (capítulo 2)	X	X				
Implementação e testes do código		X				
Experimento piloto e congelamento do protocolo		X				
Execução das 40 rodadas de treinamento			X			
Análise estatística e elaboração de gráficos			X	X		
Redação dos resultados, da discussão e da conclusão				X	X	
Revisão final e defesa						X

Fonte: elaborado pelo autor (2026).

REFERÊNCIAS

BROCK, A. *et al.* High-performance large-scale image recognition without normalization. *In*: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 38., 2021. **Proceedings** […]. [*S. l.*]: PMLR, 2021. v. 139, p. 1059-1071.

GIL, A. C. **Como elaborar projetos de pesquisa**. 6. ed. São Paulo: Atlas, 2017.

IOFFE, S.; SZEGEDY, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. *In*: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 32., 2015. **Proceedings** […]. [*S. l.*]: PMLR, 2015. v. 37, p. 448-456.

KATHAYAT, K.; AKURATHI, L. P. R.; THALLA, U. Comparing the performance of convolutional neural networks with and without batch normalization. **Global Journal of Engineering Innovations and Interdisciplinary Research**, v. 5, n. 6, 2025. DOI: 10.33425/3066-1226.1178.

KAZIMI, B.; SANDFELD, S. Enhancing semantic segmentation in high-resolution TEM images: a comparative study of batch normalization and instance normalization. **Microscopy and Microanalysis**, v. 31, n. 1, ozae093, 2025. DOI: 10.1093/mam/ozae093.

MISHKIN, D.; SERGIEVSKIY, N.; MATAS, J. Systematic evaluation of convolution neural network advances on the Imagenet. **Computer Vision and Image Understanding**, v. 161, p. 11-19, 2017. DOI: 10.1016/j.cviu.2017.05.007.

MONTGOMERY, D. C. **Design and analysis of experiments**. 9. ed. Hoboken: Wiley, 2017.

NGUYEN, K.-B.; CHOI, J.; YANG, J.-S. EUNNet: efficient un-normalized convolution layer for stable training of deep residual networks without batch normalization layer. **IEEE Access**, v. 11, p. 76977-76988, 2023. DOI: 10.1109/ACCESS.2023.3244072.

PASZKE, A. *et al.* PyTorch: an imperative style, high-performance deep learning library. *In*: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 32., 2019. **Proceedings** […]. [*S. l.*]: Curran Associates, 2019. p. 8024-8035.

WAZLAWICK, R. S. **Metodologia de pesquisa para ciência da computação**. 2. ed. Rio de Janeiro: Elsevier, 2014.

WU, S. *et al.* L1-norm batch normalization for efficient training of deep neural networks. **IEEE Transactions on Neural Networks and Learning Systems**, v. 30, n. 7, p. 2043-2051, 2019. DOI: 10.1109/TNNLS.2018.2876179.

WU, Y.; HE, K. Group normalization. *In*: EUROPEAN CONFERENCE ON COMPUTER VISION, 2018. **Proceedings** […]. Cham: Springer, 2018. p. 3-19. DOI: 10.1007/978-3-030-01261-8_1.

XIAO, H.; RASUL, K.; VOLLGRAF, R. Fashion-MNIST: a novel image dataset for benchmarking machine learning algorithms. **arXiv preprint**, arXiv:1708.07747, 2017.